

TA4: 상태공간모형, DFM

경제분석 및 예측과 데이터 지능

May 31, 2026

목차

- 1 상태공간모형
- 2 DFM
- 3 DFM 실습

- 본 TA세션에서는 수업에서 다룬 상태공간 모형, FA-VAR, GARCH에 대해 복습하고 statsmodels, arch 라이브러리를 활용하여 Dynamic Factor, GARCH를 실습한다.

상태공간모형

상태공간 모델 개요

- 상태공간 모형(State-space model)은 관찰 가능한 변수들이 숨겨진 상태(잠재 변수)로부터 생성된다는 가정에 기반하며, 이를 표현하기 위해 **측정 방정식**과 **상태 방정식**을 사용한다.
- 상태공간 모형은 (1) 현재 상태 h_t 가 과거 상태 h_{t-1} 에 의해 결정되는 동적 관계를 갖고, (2) 실제 상태 h_t 는 직접 관측되지 않으며 노이즈가 섞인 관측치 y_t 로만 표현된다는 두 가지 특징을 가진다.
- 시계열 및 분석에서 이러한 상태공간 모형을 활용한 예측이 활발하게 이루어지고 있으며, 숨겨진 동적 구조를 추정하고 예측하는 데 유리하다. FAVAR(Factor Augmented VAR)도 비슷한 맥락에서 볼 수 있다.

상태 및 관측 방정식

- 일반적인 선형 상태공간 모형은 다음과 같이 쓸 수 있다:

$$h_t = A_t h_{t-1} + B_t x_t + w_t, \quad (1)$$

$$y_t = C_t^T h_t + D_t x_t + v_t, \quad (2)$$

여기서 w_t , v_t 는 각각 과정 잡음(process noise)과 관측 잡음(measurement noise)을 나타낸다.

- 잡음 w_t , v_t 는 일반적으로 평균 0의 정규분포 ($w_t \sim N(0, Q)$, $v_t \sim N(0, R)$)로 가정한다.
- h_t 는 $n \times 1$ 상태 벡터, y_t 는 $m \times 1$ 관측 벡터, x_t 는 입력(외생 변수) 벡터이다.
- 많은 시계열 모형(예: ARIMA, 구조시계열모형 등)은 이러한 상태-공간 표현으로 나타낼 수 있으며, 칼만 필터를 통해 추정 및 예측이 가능하다.

상태공간 모델과 시계열 예측

- 매 시점 t 마다 관측값 y_t 를 통해 상태 h_t 를 추정하고 갱신함으로써 미래 상태와 관측을 예측할 수 있다. 상태공간 모델을 Reduced Form으로 쓰면 아래와 같다.

$$y_t = C_t^T A_t h_{t-1} + C_t^T B x_t + C_t^T w_t + D_t x_t + v_t \quad (3)$$

$$y_t = \sum_{s=0}^t C_t^T A_{t:s}^{\times} B_s x_s \quad (4)$$

- $h_0 = B_0 x_0$ 라는 가정 하에 위와 같이 표현할 수 있다. $\times$ 는 매트릭스의 연속된 곱을 뜻한다.

DFM

정태적 요인 모형 (Static Factor Model)

- 관측행렬 $X \in \mathbb{R}^{T \times P}$ 는 소수의 공통요인과 개별 오차의 선형결합으로 분해된다:

$$X = F\Lambda + E, \quad F \in \mathbb{R}^{T \times M}, \Lambda \in \mathbb{R}^{M \times P}, E \in \mathbb{R}^{T \times P}.$$

- 시간 t 별 관측벡터(행벡터) $x_t \in \mathbb{R}^P$ 와 요인 벡터 $f_t \in \mathbb{R}^M$ 에 대해:

$$x_t = \Lambda^T f_t + \epsilon_t, \quad \epsilon_t \in \mathbb{R}^P.$$

- 주요 가정

- $E[f_t] = 0, \quad \text{Var}(f_t) = I_M$
 - $E[\epsilon_t] = 0, \quad \text{Var}(\epsilon_t) = \Psi$ (대각행렬)
 - $\text{Cov}(f_t, \epsilon_t) = 0$
- f_t 는 변수들에 공통으로 영향을 주는 공통요인(*common factors*), ϵ_t 는 개별변수 특유의 잔차(*idiosyncratic errors*)를 의미.
- 요인 차원 $M \ll P$ 를 통해 고차원 데이터를 저차원으로 압축·해석할 수 있다.

정태적 요인 모형 II: 행렬 연산 상세

- 전체 모형(매트릭스 표기)

$$X_{T \times P} = F_{T \times M} \Lambda_{M \times P} + E_{T \times P},$$

여기서

- $X = [x^{(1)}, \dots, x^{(P)}]$ (T 시점 $\times$ P 변수)이다
 - $F = [f^{(1)}, \dots, f^{(M)}]$ (T 시점 $\times$ M 요인)이다
 - $\Lambda = [\lambda^{(1)}, \dots, \lambda^{(P)}]$ (M 요인 $\times$ P 변수)이다
 - E 는 개별잔차 행렬($T \times P$)이다
- (참고) 변수 p 의 열벡터 표현

$$x^{(p)} = F \lambda^{(p)} + \epsilon^{(p)}, \quad \lambda^{(p)} = (\lambda_{1p}, \dots, \lambda_{Mp})^\top, \quad \epsilon^{(p)} \sim N(0, \psi_p I_T)$$

이 식은 $x^{(p)}$ 가 공통요인 f_t 의 선형결합과 개별잔차 $\epsilon^{(p)}$ 로 구성됨을 나타낸다

요인 모형 예시 (T=5, P=3, M=2)

$$X_{5 \times 3} = \begin{pmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{pmatrix} \quad f_{5 \times 2} = \begin{pmatrix} f_{11} & f_{12} \\ f_{21} & f_{22} \\ f_{31} & f_{32} \\ f_{41} & f_{42} \\ f_{51} & f_{52} \end{pmatrix}$$

$$\Lambda_{2 \times 3} = \begin{pmatrix} \lambda_{11} & \lambda_{12} & \lambda_{13} \\ \lambda_{21} & \lambda_{22} & \lambda_{23} \end{pmatrix} \quad E_{5 \times 3} = \begin{pmatrix} \epsilon_{11} & \epsilon_{12} & \epsilon_{13} \\ \epsilon_{21} & \epsilon_{22} & \epsilon_{23} \\ \epsilon_{31} & \epsilon_{32} & \epsilon_{33} \\ \epsilon_{41} & \epsilon_{42} & \epsilon_{43} \\ \epsilon_{51} & \epsilon_{52} & \epsilon_{53} \end{pmatrix}$$

팩터 모형 가정

- 공통요인 $f_t = (f_{t,1}, \dots, f_{t,m}, \dots, f_{t,M})'$ 에 대한 가정
 - $E[f_t] = 0, \quad \text{Var}(f_t) = I_M$
 - $\text{Cov}(f_{t,m}, f_{t,m'}) = 0 \quad (m \neq m')$
- 개별오차 $\epsilon_t = (\epsilon_{t,1}, \dots, \epsilon_{t,p})'$ 에 대한 가정
 - $E[\epsilon_t] = 0, \quad \text{Var}(\epsilon_t) = \Psi = \text{diag}(\psi_1, \dots, \psi_p)$
 - $\text{Cov}(\epsilon_{t,p}, \epsilon_{t,p'}) = 0 \quad (p \neq p')$
- 공통요인과 개별오차 간 분리 가정 $\text{Cov}(f_{t,m}, \epsilon_{t,p}) = 0 \quad \forall m, p$
- 평균 보정 시 $E[x_t] = 0$, 비보정 시 $E[x_t] = \mu$

팩터 모형 가정 II: 분산 · 공분산 구조

$$\text{Var}(x_{t,p}) = \sum_{m=1}^M \lambda_{m,p}^2 + \psi_p \quad (p = 1, \dots, P)$$

$$\text{Cov}(x_{t,p}, x_{t,p'}) = \sum_{m=1}^M \lambda_{m,p} \lambda_{m,p'} \quad (p \neq p')$$

$$\text{Cov}(x_{t,p}, f_{t,m}) = \lambda_{m,p} \quad (m = 1, \dots, M; p = 1, \dots, P)$$

$$\text{Communality}_p = \sum_{m=1}^M \lambda_{m,p}^2$$

$$\text{Var}(X_{T \times P}) = \Lambda^\top \Lambda + \Psi, \quad \Psi = \text{diag}(\psi_1, \dots, \psi_P)$$

추정방법1: PCA

- 표본 평균 $\bar{x} = \frac{1}{T} \sum_{t=1}^T x_t$, 표본 공분산 행렬

$$S = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})(x_t - \bar{x})^T.$$

- 고유분해

$$S = E V E^T = \sum_{m=1}^P v_m e_m e_m^T \quad (5)$$

- 상위 M 개 요인만 이용한 근사

$$S \approx \sum_{m=1}^M v_m e_m e_m^T.$$

- 요인 적재행렬 Λ 구성

$$\hat{\Lambda} = [\sqrt{v_1} e_1, \dots, \sqrt{v_M} e_M] \in \mathbb{R}^{P \times M}.$$

추정방법1: PCA(잔차분산 및 Communality)

- 잔차분산 $\Psi = \text{diag}(\psi_1, \dots, \psi_P)$ 추정

$$\hat{\psi}_p = S_{pp} - \sum_{m=1}^M \hat{\lambda}_{pm}^2, \quad p = 1, \dots, P.$$

- Communality h_p 계산

$$h_p = \sum_{m=1}^M \hat{\lambda}_{pm}^2, \quad p = 1, \dots, P.$$

추정방법2: MLE

- 가정: $x_t \in \mathbb{R}^P$ 는 $N(\mu, \Sigma)$, $\Sigma = \Lambda\Lambda^\top + \Psi$. $t = 1, \dots, T$.
- 로그우도 함수

$$\ell(\mu, \Lambda, \Psi) = -\frac{TP}{2} \log(2\pi) - \frac{T}{2} \log|\Lambda\Lambda^\top + \Psi| \quad (6)$$

$$-\frac{1}{2} \sum_{t=1}^T (x_t - \mu)^\top (\Lambda\Lambda^\top + \Psi)^{-1} (x_t - \mu) \quad (7)$$

- 최적화: 로그우도함수를 최대화하는 매러미터 μ, Λ, Ψ 값을 탐색.
- 칼만필터, EM알고리즘 등이 대표적으로 활용된다.

요인이 동적이면?

- 요인의 상태 방정식 (State equation)

$$f_t = \gamma_1 f_{t-1} + \cdots + \gamma_L f_{t-L} + \eta_t, \quad \eta_t \sim N(0, \Omega) \quad (8)$$

$$f_t = \Gamma(L) f_{t-1} + \eta_t \quad (9)$$

- 해당 요인들이 모여서 측정치 x_t 에 동적으로 영향을 준다고 아래와 같이 가정한다.
- 변수의 측정 방정식 (Measurement equation)

$$x_t = \mu_t + \tilde{\Lambda}(Q) f_t + u_t$$

- $\tilde{\Lambda}(Q)$ 는 차수 Q 의 다항식 행렬($T \times M$)이다. 오차항 u_t 는 다음과 같은 구조를 가진다고 가정한다.

$$u_{tp} = \delta_p(L) u_{t-1,p} + v_{tp}$$

동적요인 모형 - 상태 공간 표현

$$h_t = \begin{pmatrix} f_t \\ f_{t-1} \\ \vdots \\ f_{t-Q+1} \end{pmatrix}, \quad f_t \in \mathbb{R}^M, \quad h_t \in \mathbb{R}^{QM}$$

$$h_t = \underbrace{\begin{pmatrix} \Gamma_1 & \Gamma_2 & \cdots & \Gamma_{Q-1} & \Gamma_Q \\ I_M & 0 & \cdots & 0 & 0 \\ 0 & I_M & \cdots & 0 & 0 \\ \vdots & & \ddots & & \\ 0 & 0 & \cdots & I_M & 0 \end{pmatrix}}_{A_{QM \times QM}} h_{t-1} + \underbrace{\begin{pmatrix} \eta_t \\ 0 \\ \vdots \\ 0 \end{pmatrix}}_{w_t}, \quad \eta_t \sim N(0, \Omega).$$

$$x_t = \underbrace{[\tilde{\Lambda}_0, \tilde{\Lambda}_1, \dots, \tilde{\Lambda}_{Q-1}]}_{C_{P \times QM}} h_t + u_t, \quad u_t \sim N(0, \Psi).$$

동적 모형 예시 (T=5, P=3, M=2, Q=4)

$$X_{5 \times 3} = \begin{pmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \\ x_{41} & x_{42} & x_{43} \\ x_{51} & x_{52} & x_{53} \end{pmatrix}, \quad f_{4 \times 2}(t) = \begin{pmatrix} f_{t-1,1} & f_{t-1,2} \\ f_{t-2,1} & f_{t-2,2} \\ f_{t-3,1} & f_{t-3,2} \\ f_{t-4,1} & f_{t-4,2} \end{pmatrix},$$

$$\Lambda^{(q)}_{2 \times 3} \quad (q = 1, \dots, 4), \quad E_{5 \times 3} = \begin{pmatrix} \varepsilon_{11} & \varepsilon_{12} & \varepsilon_{13} \\ \varepsilon_{21} & \varepsilon_{22} & \varepsilon_{23} \\ \varepsilon_{31} & \varepsilon_{32} & \varepsilon_{33} \\ \varepsilon_{41} & \varepsilon_{42} & \varepsilon_{43} \\ \varepsilon_{51} & \varepsilon_{52} & \varepsilon_{53} \end{pmatrix} \quad (10)$$

$$\forall t=1, \dots, 5, \quad p=1, 2, 3: \quad (11)$$

$$x_{t,p} = \sum_{q=1}^4 \sum_{m=1}^2 \lambda_{m,p}^{(q)} f_{t-q,m} + \varepsilon_{t,p}. \quad (12)$$

동적 요인 모형 가정

- 요인 충격 (factor innovation) η_t

$$E[\eta_t] = 0, \quad \text{Var}(\eta_t) = \Omega, \quad E[\eta_t \eta_s^\top] = 0 \quad (t \neq s)$$

- 개별 오차 (idiosyncratic error) u_t

$$E[u_t] = 0, \quad \text{Var}(u_t) = \Psi \text{ (diag)}, \quad E[u_t u_s^\top] = 0 \quad (t \neq s), \quad \text{Cov}(u_{t,i}, u_{t,j})$$

- 요인-오차 불상관 (orthogonality)

$$E[\eta_t u_s^\top] = 0, \quad \forall t, s$$

- 정상성 조건 (stationarity) companion matrix A 의 모든 고유치가 단위원 내부에 위치 ($|\lambda_i(A)| < 1$ for all i)
- 초기 상태 (initial state)

$$f_0 \sim N(0, P_0), \quad f_0 \perp \{\eta_t\}, \{\epsilon_t\}$$

FA-VAR (Vector-Augmented VAR) 도출1

$$D(L) = \text{diag}(\delta_1(L), \dots, \delta_p(L)), \quad \Lambda(L) = (I - D(L)L) \tilde{\Lambda}(L), \quad v_t = u_t - D(L) u_{t-1}.$$

$$x_t = \tilde{\Lambda}(L) f_t + u_t,$$

$$f_t = \Gamma(L) f_{t-1} + \eta_t,$$

$$u_t = D(L) u_{t-1} + v_t,$$

따라서

$$\begin{aligned} x_t &= \tilde{\Lambda}(L) (\Gamma(L) f_{t-1} + \eta_t) + D(L) u_{t-1} + v_t \\ &= \tilde{\Lambda}(L) \Gamma(L) f_{t-1} + \tilde{\Lambda}(L) \eta_t + D(L) [x_{t-1} - \tilde{\Lambda}(L) f_{t-1}] + v_t \\ &= D(L) x_{t-1} + [\tilde{\Lambda}(L) \Gamma(L) - D(L) \tilde{\Lambda}(L)] f_{t-1} + \tilde{\Lambda}(L) \eta_t + v_t \\ &= D(L) x_{t-1} + \Lambda(L) f_t + v_t, \end{aligned}$$

$$\Rightarrow (I - D(L)L) x_t = \Lambda(L) f_t + v_t.$$

FA-VAR (Vector-Augmented VAR) 도출2

$$x_t = D(L) x_{t-1} + \Lambda(L) f_t + v_t, \quad f_t = \Gamma(L) f_{t-1} + \eta_t.$$

$$z_t \equiv \underbrace{\begin{pmatrix} x_t \\ f_t \end{pmatrix}}_{(P+M) \times 1}, \quad \varepsilon_t \equiv \begin{pmatrix} v_t \\ \eta_t \end{pmatrix}.$$

$$z_t = \underbrace{\begin{pmatrix} D(L) & \Lambda(L) \\ 0_{M \times P} & \Gamma(L) \end{pmatrix}}_{A(L)} z_{t-1} + \varepsilon_t.$$

- $A(L)$ 의 좌상단 $D(L)$ 는 x 의 자체적인 lag를 뜻하고, 우상단 $\Lambda(L)$ 는 $f \rightarrow x$ state dynamics를 의미함.
- $z_t = A(L) z_{t-1} + \varepsilon_t$ 형태의 VAR 모형 완성.

칼만필터 추정 1: 예측 단계

$$\text{모형: } \underbrace{h_t}_{QM \times 1} = \underbrace{A}_{QM \times QM} h_{t-1} + w_t, \quad w_t \sim N(0, Q), \quad (13)$$

$$\underbrace{x_t}_{P \times 1} = \underbrace{C}_{P \times QM} h_t + u_t, \quad u_t \sim N(0, R). \quad (14)$$

1) 상태(요인) 예측:

$$\hat{h}_{t|t-1} = A \hat{h}_{t-1|t-1}, \quad P_{t|t-1} = A P_{t-1|t-1} A^T + Q.$$

2) 관측(측정) 예측:

$$\hat{x}_{t|t-1} = C \hat{h}_{t|t-1}, \quad \text{innovation: } \nu_t = x_t - \hat{x}_{t|t-1},$$

$$\text{innovation 공분산: } S_t = C P_{t|t-1} C^T + R.$$

칼만필터 추정 2: 갱신 단계 (칼만 이득)

3) 칼만 이득 계산:

$$K_t = P_{t|t-1} C^T S_t^{-1}.$$

4) 상태 갱신:

$$\hat{h}_{t|t} = \hat{h}_{t|t-1} + K_t \nu_t.$$

5) 공분산 갱신:

$$P_{t|t} = (I - K_t C) P_{t|t-1}.$$

- 여기서 h_t 는 $Q \times M$ 차원의 stacked factor 상태벡터, x_t 는 P 차원의 관측벡터입니다.
- A , C , Q , R 는 각각 상태전이, 측정, 과정잡음 공분산, 관측잡음 공분산 행렬입니다.
- 이 과정을 매 시점 t 마다 반복하여, 숨겨진 요인(factors)을 실시간으로 추정 · 업데이트합니다.

예시1: 금 무게 추정

- 금괴의 실제 무게 x 를 추정하는 예제. 이 시스템은 정적(static)으로 가정하여 금 무게가 짧은 기간에 변하지 않는다고 본다.
- 저울 측정값 z_n 에는 체계적인 편향은 없으나 무작위 오차가 포함된다:
 $z_n = x + v_n$.
- 초기 추정 $\hat{x}_{0|0}$ 과 공분산 $P_{0|0}$ 에서 시작하여, 각 측정 z_n 마다 다음과 같이 갱신한다:

$$\hat{x}_{n|n} = \hat{x}_{n|n-1} + K_n(z_n - \hat{x}_{n|n-1}), \quad P_{n|n} = (1 - K_n)P_{n|n-1},$$

여기서 $K_n = \frac{P_{n|n-1}}{P_{n|n-1} + \sigma^2}$

- 반복 측정이 늘어날수록 K_n 은 감소하고 추정치는 측정값의 산술평균에 수렴한다. 예를 들어 $\hat{x}_{n|n} = \frac{1}{n} \sum_{i=1}^n z_i$

예시2: 동적 요인 모형 칼만필터 1 (예측 단계)

모형 정의:

$$h_t = \underbrace{\begin{pmatrix} \Gamma_1 & \Gamma_2 & \cdots & \Gamma_Q \\ I_M & 0 & \cdots & 0 \\ 0 & I_M & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & I_M \end{pmatrix}}_A h_{t-1} + \underbrace{\begin{pmatrix} \eta_t \\ 0 \\ \vdots \\ 0 \end{pmatrix}}_{w_t}, \quad w_t \sim N(0, \text{diag}(\Omega, 0, \dots, 0)),$$
$$x_t = \underbrace{[\tilde{\Lambda}_0, \tilde{\Lambda}_1, \dots, \tilde{\Lambda}_{Q-1}]}_C h_t + u_t, \quad u_t \sim N(0, \Psi).$$

초기값:

$$\hat{h}_{0|0} = 0, \quad P_{0|0} = \text{Var}(h_0).$$

예시2: 동적 요인 모형 칼만필터 2 (관측 및 예측 단계)

1) 상태 및 관측 예측:

$$\hat{h}_{t|t-1} = A \hat{h}_{t-1|t-1}, \quad P_{t|t-1} = A P_{t-1|t-1} A^\top + Q_h,$$

$$\hat{x}_{t|t-1} = C \hat{h}_{t|t-1}, \quad \nu_t = x_t - \hat{x}_{t|t-1}, \quad S_t = C P_{t|t-1} C^\top + \Psi.$$

- $\hat{h}_{t|t-1}$: 이전 시점 추정치를 기반으로 한 *사전(state) 예측*
- $P_{t|t-1}$: 상태 불확실성(공분산)의 예측
- $\hat{x}_{t|t-1}$: 예측된 관측치, ν_t : 관측 오차(innovation)
- S_t : innovation의 분산—이후 칼만 이득 계산에 사용
- **파라미터 추정 (EM 알고리즘)**: 관측 $x_{1:T}$ 을 완전 자료로 보고, E-step에서 칼만 필터 & 스무딩을 통해 상태 $h_{t|T}$, $P_{t|T}$ 의 충분 통계량을 구하고, M-step에서 이를 사용해 A, C, Q_h, Ψ 를 closed-form(또는 최소제곱)으로 갱신
- **파라미터 추정 (MLE)**: 관측오차 ν_t 를 이용한 로그우도 $L(\theta) = \sum_t \log p(x_t | x_{1:t-1}; \theta)$ 를 직접 최대화하거나 수치 최적화로 $\theta = (A, C, Q_h, \Psi)$ 를 추정

예시2: 동적 요인 모형 칼만필터 2 (갱신 단계)

2) 칼만 이득 계산:

$$K_t = P_{t|t-1} C^\top S_t^{-1}.$$

3) 상태 갱신 (Update):

$$\hat{h}_{t|t} = \hat{h}_{t|t-1} + K_t \nu_t, \quad P_{t|t} = (I - K_t C) P_{t|t-1}.$$

- K_t : 관측 오차 대비 상태 예측 분산 비율— ν_t 반영 강도 결정
- $\hat{h}_{t|t}$: 사후(state) 추정치—예측 & 관측을 가중 결합
- $P_{t|t}$: 갱신된 상태 추정 불확실성
- **파라미터 갱신 (EM 알고리즘 M-step)**: 상태 스무딩 결과 $h_{t|T}, P_{t|T}$ 로부터 Q_h, Ψ 는 잔차 공분산으로, A, C 는 최소제곱 회귀로 각각 업데이트
- **파라미터 추정 (MLE)**: 전체 로그우도 $\sum_t \log p(x_t, x_{t-1} | \theta)$ 를 수치 최적화하여 θ 를 동시에 추정

DFM 실습

데이터 로드 및 전처리

- OECD 분기별 거시지표(GDP, 소비, 투자, 수출, 수입 등)를 CSV에서 불러와 날짜를 분기(Period) 인덱스로 변환
- 국가별 · 변수별로 열을 구성한 wide panel 형태로 재구조화 (각 분기에 모든 국가 · 변수 값이 한 행에 배치)
- 결측치 패턴 점검 및 보간 · 제거, 로그변환 또는 성장률 계산을 통해 정상성 확보
- 변수 간 스케일 차를 완화하기 위해 표준화(평균 0, 분산 1) 수행
- 최종적으로 $T \times P$ 크기의 행렬(endog)을 구성하여 DynamicFactorMQ 모델 학습에 투입
- 모델 학습 후 예측 · 스무딩 결과는 날짜 · 국가 · 변수 · 값 형태의 long 포맷으로 재변환하여 후속 분석 및 시각화에 활용

모델 정의 (DynamicFactorMQ)

$$h_t = A h_{t-1} + w_t, \quad w_t \sim N(0, Q)$$

$$x_t = C h_t + u_t, \quad u_t \sim N(0, \Psi)$$

$$h_t = [f_t^\top, \dots, f_{t-Q+1}^\top]^\top \in \mathbb{R}^{QM}$$

$$P = N_{\text{country}} \times N_{\text{var}}$$

- $N_{\text{country}} = 10, N_{\text{var}} = 5 \Rightarrow P = 50$

- M : 공통요인 수

- $A = \begin{pmatrix} \Gamma_1 & \cdots & \Gamma_Q \\ I_M & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & I_M \end{pmatrix}$

- $C = [\Lambda_0, \dots, \Lambda_{Q-1}]$

- $u_t \sim N(0, \Psi)$ (AR(1) 선택 가능)

- 추정 대상: $\{\Gamma_i\}, \{\Lambda_q\}, Q, \Psi$

모델 학습 및 시각화




Figure: factors